

UTILISER (ET SIMULER) LES PARAMÈTRES DE TEMPÉRATURE, TOP-K, TOP-P

Paramètre	Valeur	Effet recherché	Quand l'utiliser	Exemples dans les tests logiciels	Exemple de prompt avec simulation du paramètre
T° (Température) 0.1 ➔ 1.0	 Basse (0.1–0.3)	Réponse précise, stable , peu variable	Cas de test stricts, documentation normative	☒ Générer une suite de tests exhaustive à partir d'une règle métier	« Sois très rigoureux, comme si la température était à 0.1. Génère des cas de test exhaustifs à partir de cette règle : Si l'utilisateur saisit un mot de passe invalide 3 fois, il est bloqué. Ne propose aucune interprétation. »
	 Moyenne (0.4–0.6)	Bon compromis entre précision et variation	Spécifications incomplètes ou contextes interprétables	☒ Créer des cas de test à partir de user stories floues	« Sois méthodique mais ouvert à plusieurs interprétations, comme si la température était autour de 0.5. Propose 5 cas de test réalistes à partir de cette user story : "En tant qu'utilisateur, je veux modifier mon profil pour garder mes informations à jour." »
	 Haute (0.7–1.0)	Réponse créative , plus variée	Exploration, test exploratoire, idéation	☒ Identifier des comportements inattendus ou des scénarios utilisateur complexes	« Sois inventif, comme si la température était à 0.9. Imagine 10 cas de test exploratoires pour un chatbot bancaire avec saisie libre, incluant des erreurs et comportements inattendus. »
Top-K 1 ➔ 100	 Bas (K = 5–10)	Réponses homogènes, peu de variation	Production de contenu normé ou répétable	☒ Générer des cas de test automatisés stables	« Reste très cohérent et limite les variantes, comme si le top-K était à 5. Rédige 3 cas de test formels pour tester la validation d'un champ e-mail, avec des formats valides et invalides, en utilisant une structure Gherkin fixe. »

	 Moyen (K = 15–30)	Réponses diversifiées mais encore contrôlées	Génération de variantes raisonnables	☒ Obtenir plusieurs messages d'erreur cohérents	« Garde une certaine diversité dans les formulations, comme si le top-K était à 20. Donne-moi 5 formulations différentes mais cohérentes d'un message d'erreur pour un champ requis non rempli. »
	 Élevé (K = 40–100)	Réponses très variées, incluant des suggestions rares	Recherche de diversité, test de robustesse	☒ Détourner un scénario, tester des alternatives inattendues	« Sois très créatif et diversifie les propositions, comme si le top-K était à 80. Propose 5 manières inattendues mais plausibles d'utiliser une page de paiement sans finaliser l'achat. »
Top-P 0.1 → 1.0	 Bas (0.5–0.6)	Réponses concentrées sur les mots les plus probables	Rédaction cadrée, fiabilité attendue	☒ Générer des cas de test reproductibles, structuration standardisée	« Reste concentré sur les formulations les plus probables, comme si le top-P était à 0.5. Génère une liste courte de tests unitaires très typiques pour une fonction "isValidEmail" en Java. »
	 Moyen (0.7–0.85)	Bon équilibre entre rigueur et variation contrôlée	Compléter ou reformuler des tests existants	☒ Recomposer un jeu de tests avec des variations crédibles	« Propose quelques variantes crédibles sans trop t'éloigner, comme si le top-P était à 0.8. Propose 3 variantes d'un test vérifiant l'accès à un espace sécurisé avec mot de passe. »
	 Élevé (0.9–1.0)	Réponses très ouvertes, approche exploratoire	Tests exploratoires ou idées hors-norme	☒ Imaginer des usages déviants, tester des comportements utilisateur extrêmes	« Ose des suggestions inattendues, comme si le top-P était à 0.95. Quelles stratégies un utilisateur malveillant pourrait tenter pour contourner un CAPTCHA simple ? »

Valeurs recommandées de Température, Top-P et Top-K combinées

Ce document fournit un tableau de recommandations pour les paramètres Température, Top-P et Top-K selon différents objectifs dans le cadre de l'utilisation professionnelle de modèles de langage génératif (LLM).

Contexte métier	Objectif de génération	Température	Top-P	Top-K
Tests normés	Réponses rigides, prédictibles	0.1 – 0.3	0.3 – 0.5	5 – 10
Formulation standardisée (ex : messages d'erreur)	Uniformité et cohérence maximale	0.2 – 0.4	0.4 – 0.6	10 – 20
Génération de cas de test semi-structurés	Équilibre entre cohérence et variation	0.4 – 0.6	0.7 – 0.9	20 – 40
Tests exploratoires	réalistes	0.6 – 0.8	0.9 – 0.95	40 – 80
Fuzzing / créativité maximale	Diversité extrême, stress tests	0.9 – 1.0	0.95 – 1.0	80 – 120+
Simulation ultra-contrôlée	Limiter strictement les sorties	0.1 – 0.2	0.1 – 0.3	3 – 5

EXTRÊMES

Remarques :

- Une température basse (< 0.3) renforce la précision, mais diminue la créativité.
- Un Top-P élevé (> 0.9) favorise la diversité mais peut introduire du bruit.
- Un Top-K élevé (> 100) est à utiliser avec prudence, surtout si la température aussi est haute.
- L'usage combiné de ces paramètres permet un contrôle fin du comportement du modèle génératif.